# MoviesDB

Universidade de Aveiro

Inês Justo, Miguel Neves, Rafael Maio, Raquel Rainho



# MoviesDB

Departamento de Eletrónica, Telecomunicações e Informática Engenharia de Dados e Conhecimento

Universidade de Aveiro

(84804) inesjusto@ua.pt (67453) miguelneves@ua.pt (84909) rafael.maio@ua.pt (84891) raquel.a.rainho@ua.pt

22 de dezembro de 2019

# Conteúdo

1	Introdução	1
2	Dados, suas fontes e sua transformação2.1 IMDB 5000 Movie Dataset	2 2 2
3	Operações sobre os dados (SPARQL)           3.1         Operações SELECT           3.1.1         Filtros de pesquisa           3.1.2         Pesquisa por texto           3.1.3         Apresentação dos dados           3.2         Operações UPDATE           3.3         Operações ASK           3.4         Biblioteca python s4api	4 4 4 5 6 6 8 9
4	Publicação de dados semânticos através de RDFa4.1Movie_page.html4.2Actor_profile.html e Director_profile.html4.3News.html	10 10 11 13
5	Integração de dados da Wikidata	14
6	Funcionalidades da Aplicação (UI)           6.1 Filmes (Movies)            6.2 Atores (Actors)            6.3 Realizadores (Directors)            6.4 Notícias (News)	15 15 18 19 20
7	Conclusões	21
8	Configuração para Executar a Aplicação	22

# Introdução

MoviesDB é uma aplicação Web criada com o intuito de apresentar informação relativa ao mundo cinematográfico, tendo sido dividida em quatro partes principais:

- Uma secção de filmes, onde é apresentada uma lista de filmes e respetivos detalhes (tais como o ano de lançamento, géneros, pontuação, entre outros);
- Uma secção de atores, onde são listados todos os atores que participam nos filmes existentes na aplicação;
- Uma secção de realizadores, semelhante à de atores, onde são apresentados todos os realizadores dos filmes existentes;
- Uma secção de notícias, com informação atualizada sobre o mundo cinematográfico.

Para o desenvolvimento da aplicação foram utilizadas as seguintes tecnologias: Python/Django, RDF no formato N3, SPARQL, Triplestore GraphDB e RDFa.

Este projecto partilha o tema com o anterior realizado na UC, tendo sido reaproveitado grande parte da sua interface e dos dados utilizados (necessitando estes de serem adaptados ao novo formato).

# Dados, suas fontes e sua transformação

#### 2.1 IMDB 5000 Movie Dataset

O dataset "movie\_metadata.csv" (no directório "xml") foi obtido na comunidade de data scientists e machine learners, Kaggle. Embora contendo uma grande variedade de informação, este dataset não serviria um dos objetivos propostos no seu formato original. Deste modo, no projecto realizado anteriormente (em https://github.com/ijusto/Data-and-Knowledge-Engineering-Project-1.git), a transformação do CSV em XML era fundamental, pelo que se criou o ficheiro "movies.xml", bem como o ficheiro "movies short.xml".

Tendo em mente a página de informação de cada actor e realizador envolvidos nos filmes apresentados, foram guardados no ficheiro "people.xml" as fotos e biografias, retirados da base de dados IMDb, referentes a cada pessoa presente no ficheiro "movies.xml".

#### 2.2 RDF

De forma a modelar os dados conforme o objectivo do projecto, foi decidido usar o formato N3 do RDF com o auxílio de vocabulários baseados em URIs. Para conseguir que o modelo de dados se apresentasse neste formato, foi criado um *script* - o ficheiro "xmlToRDF.py" -, onde se converteu o ficheiro "movies\_short.xml", escrito em XML, para o formato pretendido. Para além da conversão deste ficheiro, foi também convertido o ficheiro "people.xml", também este escrito em XML. Finalmente, foram adicionados manualmente os triplos referentes aos géneros e *ratings*, com o objetivo de tornar as consultas mais rápidas, resultando no ficheiro "movies.n3".

```
@prefix mov: <http://moviesDB.com/entity/mov>.
@prefix person: <http://moviesDB.com/entity/person/>.
@prefix genres: <http://moviesDB.com/entity/genres/>.
@prefix ratings: <http://moviesDB.com/entity/ratings/>.
@prefix predicate: <http://moviesDB.com/predicate/>.
```

Figura 2.1: Exemplos de URIs

```
genres:horror predicate:name "Horror".
genres:mystery predicate:name "Mystery".
genres:thriller predicate:name "Thriller".
genres:action predicate:name "Action".
genres:adventure predicate:name "Adventure".
genres:fantasy predicate:name "Fantasy".
genres:sci fi predicate:name "Sci-Fi"
genres:romance predicate:name "Romance".
genres:animation predicate:name "Animation".
genres:comedy predicate:name "Comedy".
genres:family predicate:name "Family".
genres:musical predicate:name "Musical".
genres:western predicate:name "Western".
genres:drama predicate:name "Drama".
genres:history predicate:name "History".
genres:crime predicate:name "Crime".
genres:war predicate:name "War".
genres:biography predicate:name "Biography".
genres:music predicate:name "Music".
ratings:r predicate:name "R".
ratings:pg predicate:name "PG".
ratings:pg_13 predicate:name "PG-13".
ratings:g predicate:name "G".
```

Figura 2.2: Exemplos de géneros e ratings

```
predicate:year "2009";
predicate:score "7.9";
predicate:actor
         person:CCH_Pounder,
person:Wes_studi;
predicate:poster "https://m.media-amazon.com/images/M/MV5BMTYwOTEwNjAzMl5BMl5BanBnXkFtZTcwODc5MTUwMw@@._v1_UX182_CR0,0,182,268_AL_.jpg"
predicate:director
person:James Cameron;
         genres:action,
         genres:adventure
         genres:fantasy
predicate:plot_keyword
          "avatar",
         "future"
          "marine"
         "paraplegic":
predicate:country "USA";
predicate:language "English";
predicate:rating ratings:pg_13;
predicate:duration "178";
predicate:budget "237000000
```

Figura 2.3: Exemplo de um filme

```
person:Pierre_Morel
predicate:name "Pierre Morel";
predicate:profession "Director";
predicate:image "https://m.media-amazon.com/images/M/MV5BMjE3NDcyNzY4Nl5BMl5BanBnXkFtZTcwNDg5NDUxMw@a._V1_UY317_C
predicate:bio "Pierre Morel was born on May 12, 1964 in France. He is known for his work on 0s Gangs do Bairro 13
```

Figura 2.4: Exemplo de uma pessoa (ator e/ou diretor)

# Operações sobre os dados (SPARQL)

#### 3.1 Operações SELECT

Esta é a operação SPARQL mais utilizada e tem como objetivo consultar a triplestore GraphDB, retornando, de entre todas as ocorrências correspondentes à consulta solicitada, os dados pedidos. Em todas as suas utilizações, a cláusula WHERE permite que os resultados obtidos sejam apenas os triplos que obedeçam às condições impostas, como conter um predicado específico.

#### 3.1.1 Filtros de pesquisa

Quando são utilizados os filtros de pesquisa e/ou as opções de ordenação, a operação de SELECT aplicada tem como objetivo selecionar todos os triplos de um filme, usando a restrição FILTER para obter apenas os filmes pretendidos, dependendo do género, ano e/ou *rating*. Usando também o modificador ORDER BY possibilita ordenar estes resultados por ano, *score* ou título.

Caso sejam selecionados vários géneros, são obtidos filmes com todos ou apenas algum(ns) deles, mas no caso de ser selecionado um rating e/ou ano específicos, os filmes obtidos contêm obrigatoriamente esses valores. (Por exemplo, sendo feita uma filtragem com *Genres: "Action", "Adventure"; Rating: "PG"; Year: "2001"*, são obtidos filmes com a classificação "PG", do ano 2000 e dos géneros de ação e/ou aventura.)

Figura 3.1: Query de filtros de pesquisa

#### 3.1.2 Pesquisa por texto

Na página inicial, responsável por listar os filmes, o utilizador pode pesquisar por palavras contidas no título ou nas palavras-chave (plot keywords) de um filme. Neste caso, a operação utilizada contém a restrição FILTER para restringir os resultados a apenas aqueles que contenham o texto pesquisado nos campos mencionados.

Figura 3.2: Query de pesquisa de filmes

Nas páginas de atores e realizadores, o utilizador pode ainda pesquisar pelo nome de um destes. Ambas as pesquisas são feitas inserindo o nome, ou parte deste, de um determinado ator ou realizador. De forma idêntica à pesquisa mencionada anteriormente, a restrição FILTER permite obter como resultados apenas os atores/realizadores cujo nome contenha o texto introduzido.

Figura 3.3: Query de pesquisa de atores

Figura 3.4: Query de pesquisa de realizadores

#### 3.1.3 Apresentação dos dados

De forma a apresentar toda a informação relativa a um filme, a operação de pesquisa retorna todos os triplos a ele associados, sendo utilizada a restrição REGEX para obter apenas resultados cujo sujeito tenha o nome do filme desejado. A informação retirada destes é organizada conforme a relação (predicado) de cada item com o filme.

A obtenção da informação relativa a um ator ou realizador é feita de maneira semelhante, e utilizada na apresentação das suas páginas pessoais.

Figura 3.5: Query de pesquisa de um filme

```
in res['results']['bindings']:
          in e['pred']['value']:
 name = e['obj']['value']
f "year" in e['pred']['value']:
 year = e['obj']['value']
                in e['pred']['value']:
  "poster"
 poster = e['obj']['value']
 "poster" in e['pred']['value']:
poster = e['obj']['value']
   "score"
               in e['pred']['value']:
  score = e['obj']['value']
   "actor" in e['pred']['value']:
 movie_main_actors.append(e['obj'
   "director" in e['pred']['value']
 movie_director = e['obj']['value']
f "genre" in e['pred']['value']:
  movie_genres.append(e['obj']['value'])
f "plot_keyword" in e['pred']['value']:
  plot_keywords.append(e['obj']['value'])
 f "country" in e['pred']['value']:
  country = e['obj']['value']:
f "language" in e['pred']['value']:
  language = e['obj']['value']
  "rating" in e['pred']['value']:
 rating = e['obj']['value']
= "duration" in e['pred']['
 "duration" in e['pred']['value']:
duration = e['obj']['value']
   "budget" in e['pred']['value']:
 budget = e['obj']['value']
```

Figura 3.6: Organização da informação resultante da query de pesquisa de um filme

#### 3.2 Operações UPDATE

As operações UPDATE são responsáveis por atualizar a triplestore GraphDB. Podem ser de dois tipos, INSERT e DELETE, que correspondem à inserção e eliminação de dados, respetivamente. Estas atualizações podem ser feitas diretamente (por exemplo, na adição de um novo filme, a inserção do triplo que associa o seu ano é feita diretamente, explicitando o URI para a entidade correspondente ao filme e o literal correspondente ao ano - figura 3.7) ou indiretamente (por exemplo, na adição de um novo filme, a inserção do triplo que associa um dos seus géneros é auxiliada por uma "pesquisa" da entidade relativa a esse género - figura 3.8).

Figura 3.7: Query de inserção direta de um novo filme

Figura 3.8: Query de inserção indireta de um novo filme

Como se pode verificar na figura 3.9, a operação exemplificada é responsável por apagar todos os triplos relativos a um dado filme, passando este a não estar presente na base de dados e deixando assim de ser possível encontrá-lo na página web.

```
update = """
    prefix predicate: <http://moviesDB.com/predicate/>
    DELETE {?film ?pred ?obj.} where{
        ?film ?pred ?obj.
        ?film predicate:name ?name.
        filter regex(?name,\"""" + movie + """\","i").
    }
    """
```

Figura 3.9: Query de remoção de um filme

#### 3.3 Operações ASK

São utilizadas operações ASK na validação dos dados de um novo filme a inserir na base de dados, para verificar se o(s) género(s) e *rating* introduzidos existem na base de dados.

Figura 3.10: Query de validação dos géneros do novo filme

Figura 3.11: Query de validação do rating do novo filme

Exemplo de dados válidos para um novo filme a inserir:

MovieDB			
New movie			
Title: *			
Saw			
Year: *			
2004			
Director: *			
First name: James Last name: Wan			
Actor 1:*			
First name: Cary Last name: Elwes			
Actor 2: *			
First name: Leigh Last name: Whannell			
Actor 3: *			
First name: Danny Last name: Glover			
Duration: *			
103			
Genres:			
Horror * Mystery			
Thriller			
Rating: *			
R			
Country:			
Budget:			
1200000			
* - required			
Submit			

Figura 3.12: Página para inserção de um filme na base de dados

#### 3.4 Biblioteca python s4api

Com o intuito de consultar a base de dados presente na triplestore GraphDB e obter a informação necessária para ser mostrada nas diferentes funcionalidades da aplicação, ou até mesmo atualizar a base de dados, usou-se a biblioteca  $python\ s \not 4 api$ , que implementa as operações básicas de acesso, via REST. Os resultados das operações SPARQL são retornados no formato de um dicionário, através do qual os dados são transformados para serem utilizados da forma pretendida (figura 3.6).

# Publicação de dados semânticos através de RDFa

Até recentemente, a informação apresentada nas páginas Web tem sido organizada maioritariamente para consumo humano. Apesar dos *browsers* conseguirem exibir facilmente a informação, os computadores não conseguem perceber o significado do conteúdo exposto.

A utilização de RDFa serve precisamente para especificar a semântica por trás da informação apresentada, de modo a poder ser interpretada pela máquina.

A aplicação MoviesDB faz uso de RDFa nas páginas HTML "movie\_page.html", "actor\_profile.html", "director\_profile.html" e "news.html", utilizando o vocabulário de *schema.org* para descrever os tipos de dados.

#### 4.1 Movie page.html

A informação apresentada nesta página mostra os detalhes de um determinado filme, portanto foi utilizado o tipo "Movies". Para os atributos foram utilizadas as propriedades "name" (para o nome do filme), "datePublished" (para o seu ano de publicação), "duration" (para a sua duração), "genre" (para os géneros a que o filme pertence), entre outros. Foram também utilizadas as propriedades "actor" e "director" que, como se referem a pessoas, foram caracterizadas pelo tipo "Person".

Figura 4.1: Excerto de código de "movie\_page"

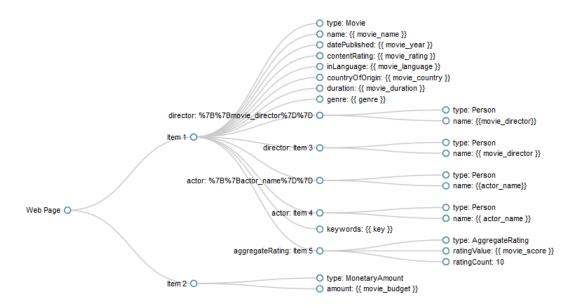


Figura 4.2: Visualização dos dados de "movie page"

#### 4.2 Actor profile.html e Director\_profile.html

Em "actor\_profile"/"director\_profile", é apresentada informação de um determinado ator/realizador, contendo uma foto, o seu nome e biografia. Para este caso, foi utilizado o tipo "Person"e as propriedades "image", "name"e "description".

Figura 4.3: Excerto de código de "actor profile"

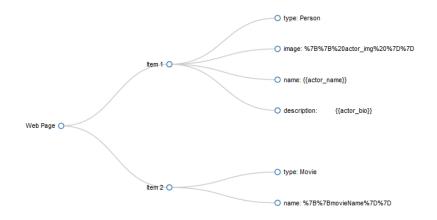


Figura 4.4: Visualização dos dados de "actor\_profile"

Figura 4.5: Excerto de código de "director profile"

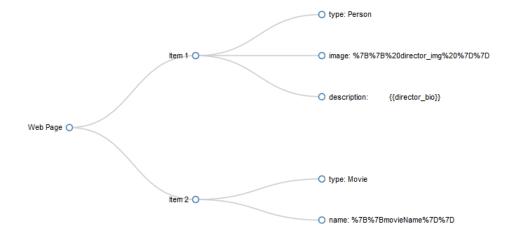


Figura 4.6: Visualização dos dados de "director\_profile"

#### 4.3 News.html

A escolha de um tipo que representasse esta página não foi trivial, no entanto optou-se por se utilizar "Article", visto que conseguia caracterizar bem a informação existente. Foram utilizadas as propriedades "name" (para o título da notícia), "author" (para o seu autor), "datePublished" (para a sua data de publicação) e "identifier" (para o link onde foi publicada a notícia).

Figura 4.7: Excerto de código de "news"

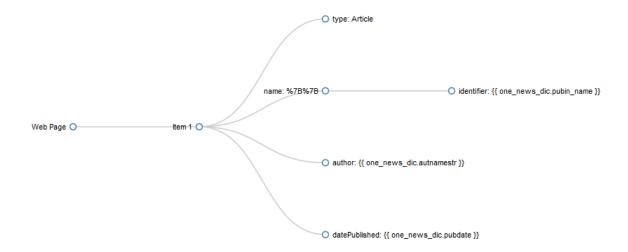


Figura 4.8: Visualização dos dados de "news"

# Integração de dados da Wikidata

Com vista a alcançar um dos objetivos propostos para este trabalho, bem como pela sua utilidade e dada a facilidade de pesquisa sobre a mesma, foram integrados na aplicação final dados provenientes da Wikidata. No contexto do tema da aplicação, e tendo em conta o tipo de dados que não estão armazenados na base de dados do projeto, tomou-se a decisão de procurar dados relativos a notícias de filmes na base de dados da Wikidata.

Assim sendo, acedendo à página relativa ao item "news article", foi possível detetar quais as suas propriedades relevantes para visualização na página de notícias da aplicação. A forma utilizada para procurar apenas artigos de notícias sobre filmes foi filtrando os artigos cujo url contivesse a palavra "movies".

#### news article (Q5707594)

```
article that is published in news media
```

magazine article | web article | article | newspaper article

Figura 5.1: Excerto da página de News Article na Wikidata

```
Wikidata Query Service
                                1 SELECT DISTINCT ?itemTitle ?autnamestr ?pubin name ?pubdate ?arc url
                       instanceof newsarticle
                 ?item_wdt:P31
                                   wd:05707594:
耳.
                       title
                       wdt:P1476
                                  ?itemTitle;
archiveURL
                       wdt:P1065
published in
                       wdt:P1433
                                  ?pubin;
                       author name string
                       wdt:P2093 ?autnamestr;
                       publication date
                       wdt:P577
                                  ?pubdate.
                 ?pubin wdt:P856
                                   ?pubin_name.
                 FILTER(REGEX(STR(?arc_url), "movies"))
     17 }
```

Figura 5.2: News Article query sobre os dados da Wikidata

# Funcionalidades da Aplicação (UI)

Tal como referido no Capítulo 1, as funcionalidades da aplicação podem agrupar-se em quatro áreas principais, focando-se em filmes, atores, realizadores e notícias. É de referir que a navegabilidade entre estas pode ser realizada de diversas formas, pois todos os títulos de filmes e nomes de atores e realizadores redirecionam o utilizador para a sua página detalhada (caso existam na base de dados).

#### 6.1 Filmes (Movies)

• Visualizar a lista de filmes existentes na base de dados;

Movies

# Avatar (2009) [Action][Adventure][Fantasy] Director: James Cameron Cast: - CCH\_Pounder - Joel\_Moore - Wes\_Studi 7.9/10 Spectre

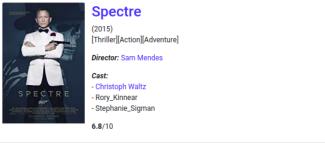


Figura 6.1: Exemplo de vista de filmes

- Pesquisar por filmes de um determinado género (genre), classificação (rating), ano de lançamento (year) ou qualquer combinação destes;
- Ordenar os filmes por título (title), ano de lançamento (year) ou pontuação (score);



Figura 6.2: Filtros e ordenação

• Pesquisar por texto, contido no título ou palavras-chave (plot keywords) de um filme;

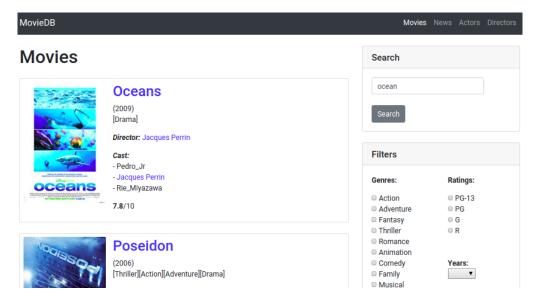


Figura 6.3: Pesquisa de filmes com o termo "ocean"

• Adicionar um filme à base de dados, utilizando o botão respetivo (New movie);

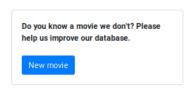


Figura 6.4: Botão para adicionar um novo filme

- Aceder aos detalhes de um filme específico, clicando no seu título;
- $\bullet\,$  Remover um filme da base de dados, utilizando o botão presente nos detalhes do filme (Delete).

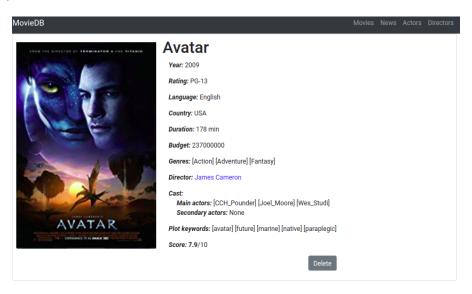


Figura 6.5: Página detalhada do filme "Avatar"

#### 6.2 Atores (Actors)

• Visualizar todos os atores dos filmes existentes na base de dados;

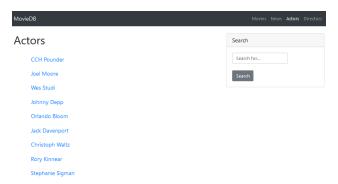


Figura 6.6: Exemplo de atores que participam em filmes existentes na base de dados

• Pesquisar atores pelo seu nome;

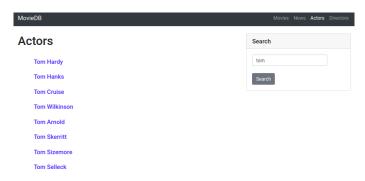


Figura 6.7: Pesquisa de atores cujo nome contém "tom"

- Aceder ao perfil de um ator (que contém a sua mini-biografia e uma fotografia), clicando no seu nome;
- Verificar, no perfil do ator, quais os filmes em que participa.

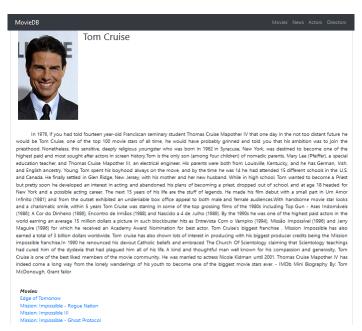


Figura 6.8: Detalhes do ator "Tom Cruise" e lista de filmes em que participou

#### 6.3 Realizadores (Directors)

• Visualizar todos os realizadores dos filmes existentes na base de dados;

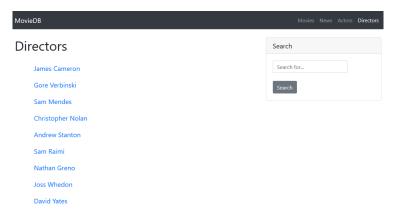


Figura 6.9: Exemplo de realizadores que dirigem filmes existentes na base de dados

• Pesquisar realizadores pelo seu nome;



Figura 6.10: Pesquisa de realizadores cujo nome contém "cameron"

- Aceder ao perfil de um realizador (que contém a sua mini-biografia e uma fotografia), clicando no seu nome;
- Verificar, no perfil do realizador, quais os filmes que dirige.

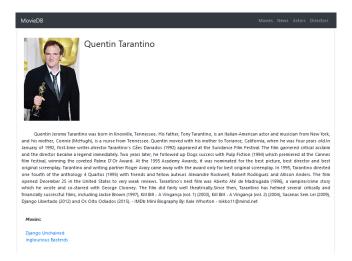


Figura 6.11: Detalhes do realizador "Quentin Tarantino" e lista de filmes que dirigiu

#### 6.4 Notícias (News)

• Apresentar cabeçalhos das últimas notícias cinematográficas, com redirecionamento para a fonte destas, onde é possível consultar a notícia completa.

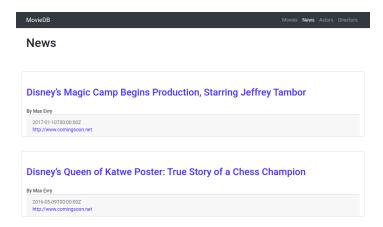


Figura 6.12: Exemplo de cabeçalhos de notícias cinematográficas

# Conclusões

O projecto apresentado permitiu atingir todos os objectivos propostos, pois foi dado um propósito real para todas as tecnologias propostas e utilizadas.

Foi desenvolvido em grande parte o conhecimento na área da informação e da organização e representação de dados, um ponto fundamental neste e em qualquer projeto na área das tecnologias de informação.

Em suma, a aplicação desenvolvida permite um fácil e intuitivo acesso às principais informações sobre filmes, atores e realizadores, através de boa organização, apresentação de dados e navegabilidade.

# Configuração para Executar a Aplicação

- 1. Através da aplicação GraphDB, criar uma base de dados com o Repository ID "moviesDB", Base URL "http://moviesDB.com" e restantes definições pré-definidas, e importar o ficheiro "movies.n3" (ou, no caso de se desejar utilizar uma base de dados menor, para acelerar as operações e consequentemente a navegação pelo website, importar o ficheiro "movies\_short.n3"), que se encontra em "webproj\app\data\n3";
- 2. Instalar as dependências do projecto listadas com a respectiva versão no ficheiro requirements.txt (no directório "webproj") através do PyCharm ou utilizando o comando "pip install -r requirements.txt".
- 3. Inicializar a aplicação em si, através do PyCharm, e aceder a http://127.0.0.1:8000/ no browser.

# Acrónimos

CSV Coma Separated Values

 $\mathbf{XML}$  Extensible Markup Language

**RDF** Resource Description Framework

N3 Notation 3

 ${\bf RDFa}\,$  Resource Description Framework Attributes

 ${\bf SPARQL}\,$  Simple Protocol and RDF Query Language

**URI** Uniform Resource Identifier

 $\mathbf{HTML}$  HyperText Markup Language

# Bibliografia

- $[1] \ \ Kaggle \ ({\tt https://www.kaggle.com/carolzhangdc/imdb-5000-movie-dataset})$
- [2] RDFa 1.1 Primer Third Edition (https://www.w3.org/TR/rdfa-primer/#introduction)
- [3] Wikidata (http://www.wikidata.org)